

5 基于双分支 PINN 的像素级电磁逆散射研究

5.1 引言

第4章主要研究了参数级电磁逆散射问题,通过预设目标的几何形状与介电常数,将反演问题转化为有限维参数的恢复问题。然而,当目标形态复杂、内部介电常数分布未知且难以用少量参数准确表征时,参数级方法的适用性受到限制。相比之下,像素级电磁逆散射直接以目标区域内的介电常数空间分布为重建对象,能够更灵活地描述复杂目标,但同时也面临未知量维数高、不适定性强以及成像稳定性不足等问题。针对传统单分支 PINN 在像素级成像中易出现角度耦合不合理、梯度竞争明显、边界恢复能力不足及噪声条件下鲁棒性较差等问题,本章构建了场预测与介电常数反演的双分支 PINN 框架,并进一步引入边缘保持正则化与残差自适应数据一致性重加权方法,以提高复杂目标和噪声条件下的成像精度与稳定性,随后通过规则目标、不同噪声水平下的复杂目标以及实验数据三个算例,对所提方法的有效性进行验证。

5.2 基于 PINN 框架的像素级电磁逆散射方法

与参数级电磁逆散射通过预设几何模型并恢复有限维参数向量不同,像素级电磁逆散射不再对目标结构作先验参数化假设,而是直接重建各空间位置上的介电常数分布。因此,其未知量不再是少量可显式更新的参数,而是与空间坐标直接相关的高维分布函数。由于散射场预测与介电常数恢复在任务属性和优化特征上并不一致,传统单分支 PINN 在像素级逆散射中容易出现梯度冲突以及细节重构不足等问题。为此,本节在前文的建模思想基础上,构建场预测与介电常数反演双分支结构 PINN 框架,并从贴合实际问题的角度对框架进行优化,实现像素级介电常数分布的高精度重建。

5.2.1 场预测与介电常数反演双分支结构 PINN 框架

本章仍考虑二维 TM 极化条件下的频域电磁逆散射问题。设整个求解空间记为全域 S , 目标域 D 为 S 的子域, D 内包含待恢复介电常数分布的散射体,背景区域为均匀自由空间。通过在一个或多个入射方向 θ 下获取观测散射场数据,并利用这些观测信息反演目标域内的介电常数空间分布,从而实现电磁成像。

像素级电磁逆散射的目标是恢复目标域 D 内完整的介电常数空间分布,而非像第

4 章参数级逆散射那样仅恢复固定介电常数、几何尺寸等有限维参数。设目标域内真实相对介电常数分布记为 $\varepsilon_r(x, y)$ ，由于该分布随空间位置连续变化，且一般不存在可直接利用的低维几何先验，因此若仍沿用参数级逆散射中将未知量作为显式参数直接更新的处理方式，不仅难以表达复杂目标的介电常数分布，也会因未知量数量过大而显著增加优化难度。

基于这一原因，本章不再将介电常数视为少量待更新参数，而是将其作为网络输出，由网络通过空间坐标到介电常数分布的映射直接给出目标域内的重建结果，因此网络的输出为 $\hat{\varepsilon}_r$ 和 $\hat{E}_s$ 。

同时，在像素级电磁逆散射中，散射场分布与介电常数分布虽然耦合于同一物理系统之中，但二者具有不同的物理属性。对于固定目标而言，介电常数分布 $\varepsilon_r(x, y)$ 仅由空间位置决定，与入射角 θ 无关；而散射场 $E_s(x, y, \theta)$ 则同时依赖于空间坐标和入射条件，是典型的角度相关量。若仍采用前文中的单分支 PINN，将 (x, y, θ) 统一输入同一网络并同时输出场和介电常数分布，则会使角度信息不合理地混入介电常数恢复路径，从而导致同一空间位置在不同入射角下可能对应不同的介电常数预测结果，这显然不符合实际物理规律。




图 5.1 场预测与介电常数反演双分支结构 PINN 框架

同时，场值拟合更强调满足多视角下的控制方程和观测数据约束，而介电常数恢复更强调重建空间分布中的局部突变、边缘位置和高对比度特征，二者共用同一网络路径时容易在反向传播过程中产生梯度竞争。基于上述考虑，本文构建场预测与介电常数反演双分支结构 PINN 框架，从网络结构层面对角度相关任务和角度无关任务进

行显式隔离。

在该框架中，网络结构由场预测分支和介电常数反演分支两部分组成，二者在结构上相互独立，在物理残差与数据残差层面重新耦合，其基本框架示意图如图 5.1 所示。主要包括四个部分：（1）输入，（2）场预测分支，（3）介电常数反演分支，（4）耦合与损失模块。具体设计如下：

（1）输入。对于场预测分支，为了统一处理不同入射方向下的散射响应，输入仍采用前文参数级逆散射中已经建立的多视角编码方式，即：

$$\mathbf{x}_f = [x, y, \boldsymbol{\theta}]^T \quad (5.1)$$

式中， $\boldsymbol{\theta}$ 表示入射平面波与 x 轴正方向之间的夹角。对于介电常数反演分支，由于介电常数分布与入射角无关，因此其输入只取空间坐标，即：

$$\mathbf{x}_e = [x, y]^T \quad (5.2)$$

这种输入隔离方式保证了介电常数恢复路径不受角度变量干扰，从结构上避免了非必要的角度耦合。

（2）场预测分支。设场预测分支记为 N_e 。该分支负责建立空间坐标、入射角与多视角散射场之间的映射关系，并输出对应的复值散射场预测结果。数值实现上，仍可沿用前文对复值场的常规处理方式，但此处不再展开场的分量表示。进一步地，为延续前文硬约束边界处理思想，仍构造边界包络函数 $B(x, y)$ ，使其在计算域外 PML 边界上恒为零，在区域内部非零，从而将边界条件直接嵌入网络输出中。于是，最终散射场预测值写为：

$$\hat{E}_s(x, y, \boldsymbol{\theta}) = B(x, y)Z(x, y, \boldsymbol{\theta}) \quad (5.3)$$

其中， $Z(x, y, \boldsymbol{\theta})$ 为网络先输出未受约束的散射场预测。

（3）介电常数反演分支。介电常数反演分支记为 N_ϵ 。该分支的任务是直接输出目标域内各空间位置的相对介电常数预测值，介电常数反演分支并不接收入射角信息，而是仅根据空间坐标直接输出介电常数分布。这样，同一空间位置在不同入射条件下将始终对应同一个介电常数预测值，从而保证了介电常数分布的物理一致性。

（4）耦合模块。虽然两条分支在结构上相互分离，但它们并非彼此独立训练，而是通过统一的耦合模块在物理方程层面重新连接。本文所设计的耦合模块本身不额外引入新的可训练网络，其作用是在每个训练批次中，将场预测分支输出的 $\hat{E}_s(x, y, \boldsymbol{\theta})$

与介电常数反演分支输出的 $\hat{\epsilon}_r(x, y)$ 按照控制方程要求进行组合。具体而言, 对于每一个内部配点样本 (x_n^f, y_n^f, θ_q) , 首先由场预测分支得到对应的散射场预测 $\hat{E}_s(x_n^f, y_n^f, \theta_q)$; 再由介电常数反演分支得到同一空间位置 (x_n^f, y_n^f) 处的介电常数预测 $\hat{\epsilon}_r(x_n^f, y_n^f)$ 。由于介电常数分布与角度无关, 耦合模块会将该空间位置处的 $\hat{\epsilon}_r$ 复制到所有入射角样本上, 使其与不同入射角下的场预测逐一对应。随后, 将已知入射场 $E_i(x, y, \theta)$ 与散射场预测值相加, 得到预测总场:

$$\hat{E}(x, y, \theta) = E_i(x, y, \theta) + \hat{E}_s(x, y, \theta) \quad (5.4)$$

再将 $\hat{E}(x, y, \theta)$ 与 $\hat{\epsilon}_r(x_n^f, y_n^f)$ 共同代入控制方程残差中。这样, 双分支的输出就在耦合模块中完成了场和介质的组合, 并统一服务于后续损失函数的构建。

于是, 内部配点上的物理残差损失定义为:

$$L_f = \frac{1}{N_f N_\theta} \sum_{q=1}^{N_\theta} \sum_{n=1}^{N_f} \left| \left(\nabla_{\text{PML}}^2 + k_0^2 \hat{\epsilon}_r(x_n^f, y_n^f) \right) \hat{E}(x_n^f, y_n^f) \right|^2 \quad (5.5)$$

其中, N_f 表示区域内的内部物理配点总数, N_θ 表示入射角数量。另一方面, 在观测数据约束上, 对应的多视角观测散射场数据记为 $E_s^{\text{obs}}(x_p^d, y_p^d, \theta_q)$, 一个观测角度下共 N_d 个。则数据残差损失可写为:

$$L_d = \frac{1}{N_d N_\theta} \sum_{q=1}^{N_\theta} \sum_{p=1}^{N_d} \left| \hat{E}_s(x_p^d, y_p^d, \theta_q) - E_s^{\text{obs}}(x_p^d, y_p^d, \theta_q) \right|^2 \quad (5.6)$$

此时, 双分支框架下的基本总损失函数可表示为:

$$L = \lambda_f L_f + \lambda_d L_d \quad (5.7)$$

式中, λ_f 和 λ_d 分别为物理残差损失和数据残差损失的权重系数。

综上, 本节构建的场预测与介电常数反演双分支结构 PINN 框架, 并非简单增加一条网络支路, 而是基于像素级电磁逆散射中物理特性, 对任务进行显式解耦, 并通过耦合模块在控制方程残差与观测数据残差层面重新建立联系。该框架一方面继承了前文多视角输入、激活函数和采样策略以及硬约束边界处理等技术优势, 另一方面又使高维介电常数分布能够作为网络输出直接重建。

5.2.2 像素级逆散射的边缘保持正则化方法

在像素级电磁逆散射中, 待恢复对象为目标域内的介电常数空间分布, 其自由度远高于参数级逆散射, 因此不适定性更强, 介电常数重建结果中可能出现局部振荡、细碎伪影以及边界模糊等现象。尤其对于高对比度目标, 若缺乏适当先验, 网络虽然

能够恢复介电常数的大体分布，但在目标内部均匀区域和背景区域中容易出现非物理起伏，从而影响成像精度与边界可辨性。基于此，本文进一步引入正则化约束，对介电常数反演分支输出施加附加限制。

最直接的做法是采用二次型平滑约束^[89]，对介电常数空间梯度进行平方惩罚，其形式可写为：

$$L_{sm} = \frac{1}{N_r} \sum_{n=1}^{N_r} \left[\left(\frac{\partial \hat{\epsilon}_r(x_n^r, y_n^r)}{\partial x} \right)^2 + \left(\frac{\partial \hat{\epsilon}_r(x_n^r, y_n^r)}{\partial y} \right)^2 \right] \quad (5.8)$$

式中， (x_n^r, y_n^r) 表示用于正则化计算的采样点， N_r 为相应采样点总数。该正则项能够抑制介电常数分布中的高频振荡，使重建结果更加平滑。然而，这种处理虽然能够降低局部振荡，但同时也会削弱真实边界处的梯度变化，导致目标轮廓被过度抹平，从而损失成像分辨率。为了在抑制区域内非物理波动的同时尽量保留真实界面，本文进一步采用边缘保持正则化项，对介电常数梯度进行非二次惩罚。相应地，定义边缘保持正则项为：

$$L_{ep} = \frac{1}{N_r} \sum_{n=1}^{N_r} \sqrt{\left(\frac{\partial \hat{\epsilon}_r(x_n^r, y_n^r)}{\partial x} \right)^2 + \left(\frac{\partial \hat{\epsilon}_r(x_n^r, y_n^r)}{\partial y} \right)^2} + \delta^2 \quad (5.9)$$

式中， δ 为防止数值不稳定而引入的较小正常数。该正则项本质上仍然约束介电常数空间梯度，但与二次型惩罚不同，它对较大梯度的压制相对缓和。因此，当 $\hat{\epsilon}_r(x, y)$ 在目标内部或背景区域变化较小时，能够有效抑制细碎波动；而当介电常数在真实界面处发生突变时，其对大梯度保持相对宽容，从而有利于保留边缘清晰度。

图 5.2 直观地说明本文引入的边缘保持正则项的作用，即在相同条件下，同时使用普通二次型平滑约束和本文引入的边缘保持正则项的 PINN 对一个介电常数为 4 的圆形介质体进行成像。可见相较于普通二次型平滑约束，边缘保持正则化能够更好地兼顾区域平滑性与界面清晰度。

在引入边缘保持正则化后，双分支 PINN 中的基本总损失函数可进一步写为：

$$L = \lambda_f L_f + \lambda_d L_d + \lambda_{ep} L_{ep} \quad (5.10)$$

式中， λ_{ep} 为边缘保持正则项的权重系数。

需要指出的是， L_{ep} 仅直接作用于介电常数反演分支的输出，不直接约束场预测分支；但由于介电常数分布又通过耦合模块进入控制方程残差，因此该正则项会间接影

响场预测与介电常数恢复的协同过程，从而提高整体成像稳定性。




图 5.2 像素级电磁逆散射不同约束的结果对比。(a)普通二次型平滑约束；(b)本文引入的边缘保持正则项

5.2.3 残差自适应的数据一致性重加权方法

在实际电磁逆散射成像中，观测散射场通常会受到测量误差和环境扰动的噪声影响。对于像素级逆散射而言，由于待恢复对象是目标域内完整的介电常数空间分布，网络对观测数据中的局部异常噪声更加敏感。当观测数据中存在较强扰动时，成像结果中容易出现伪影增强、边界破碎以及局部异常起伏等现象，从而影响介电常数分布的稳定重建。为此，在 5.2.1 节双分支 PINN 框架和 5.2.2 节边缘保持正则化的基础上，本文进一步引入残差自适应的数据一致性重加权方法，对观测数据约束的参与强度进行动态调节，以提升 PINN 在复杂噪声条件下的优化稳定性与成像鲁棒性。

考虑到实际问题中通常难以预先准确获知噪声是否存在及其具体大小，本文不显式引入噪声强度参数，而是依据当前迭代下的观测残差评估各样本的相对可信度^[90]。设第 p 观测点在第 q 个入射角下的数据残差为：

$$r_{p,q}^{(t)} = \hat{E}_s^{(t)}(x_p^d, y_p^d, \theta_q) - E_s^{\text{obs}}(x_p^d, y_p^d, \theta_q) \quad (5.11)$$

其中，上标 t 表示第 t 次迭代。

为了减弱不同训练阶段残差整体量级变化对权重分配的影响，定义当前批次的平均残差幅值为：

$$\bar{r}^{(t)} = \frac{1}{N_d N_\theta} \sum_{q=1}^{N_\theta} \sum_{p=1}^{N_d} |r_{p,q}^{(t)}| \quad (5.12)$$

在此基础上，构造残差自适应权重：

$$w_{p,q}^{(t)} = \frac{1}{1 + \frac{|r_{p,q}^{(t)}|}{\gamma \bar{r}^{(t)} + \delta}} \quad (5.13)$$

式中， γ 为调节系数， δ 为较小正常数。由上式可见，当某一观测样本的残差低于当前整体平均水平时，其对应权重更接近于 1，说明该样本与当前预测结果具有较好一致性，在训练中应赋予更高可信度；而当某一样本残差明显偏大时，其权重将自动减小，从而削弱异常样本对参数更新的干扰。这样，观测数据约束便由固定等权形式转变为按残差大小进行自适应调节的形式，整个过程无需预先给定噪声水平。

该权重并不是额外引入的可训练参数，而是在每次迭代中由当前预测结果直接计算得到，并随训练过程动态更新。具体而言，在每一次前向传播后，先计算观测点上的残差，再由残差更新各样本权重，随后将其代入数据残差损失中完成反向传播与参数更新。进入下一次迭代后，由于网络预测发生变化，残差及其对应权重也会重新计算。

训练初期，由于整体残差普遍较大且不同样本之间差异有限，各权重通常较为接近；随着训练逐步收敛，部分异常样本与大多数样本之间的残差差异会逐渐显现，其权重便会被自动压低，从而避免少数异常点持续主导网络优化方向。

在引入上述动态权重后，重加权后的数据残差损失可写为：

$$L_d^w = \frac{1}{N_d N_\theta} \sum_{q=1}^{N_\theta} \sum_{p=1}^{N_d} w_{p,q}^{(t)} |\hat{E}_s^{(t)}(x_p^d, y_p^d, \theta_q) - E_s^{\text{obs}}(x_p^d, y_p^d, \theta_q)|^2 \quad (5.14)$$

于是，5.2.2 节中的总损失函数可进一步写为：

$$L = \lambda_f L_f + \lambda_d L_d^w + \lambda_{ep} L_{ep} \quad (5.15)$$

从训练演化的角度来看，该重加权策略在不同阶段发挥的作用并不完全相同。训练初期，网络预测偏差整体较大，各观测样本之间的残差差异尚不显著，因此权重分布较为接近，该阶段数据项主要起到提供整体优化方向的作用；随着训练不断推进，部分异常样本与正常样本之间的残差差异逐步放大，权重调节机制便开始更加明显地削弱异常观测点对梯度更新的主导作用，从而避免网络在局部错误信息附近反复震荡。由此可见，该方法实际上在训练后期对鲁棒性提升更为关键，这也为后续噪声条件下复杂目标成像结果的改善提供了机制上的解释。

5.3 数值仿真验证及结果分析

5.3.1 仿真设置与评价指标

本章数值实验均针对二维 TM 极化频域像素级电磁逆散射问题开展，通过两个数值仿真案例和一个实验案例来验证所提出的双分支 PINN 技术。求解域 S 为边长为 2 m 的正方形区域，目标活动区域 D 为边长 1 m 的正方形区域，背景介质为空气， S 外围设置 PML 吸收层。观测散射场数据由 FEM 生成，并作为后续像素级成像的参考输入数据。观测点布设在域 S 内部半径为 0.75 m 的圆周上，均匀取 360 个采样点；入射采用多视角平面波激励，但角度数量和具体取值根据算例的不同有所差异。

在本章方法中，场预测分支输入为 (x, y, θ) ，介电常数反演分支输入为 (x, y) ，二者通过耦合模块在物理残差与数据残差中统一训练。为保证不同算例之间的可比性，本章相关实验中的双分支 PINN 均采用一致的网络与优化设置：网络主体均取为全连接前馈网络，隐藏层数、每层神经元数和激活函数、采样点数与第 4 章保持一致；训练过程采用 Adam+L-BFGS-B 两阶段优化策略。总损失函数由物理残差项、残差自适应重加权形式的数据项以及边缘保持正则项共同构成，三者的权重 λ_f 、 λ_d 、 λ_{ep} 分别设置为 1、100、100。

为验证所提方法的有效性，后续数值实验中选取原始 PINN 方法和子空间优化方法（SOM）作为对比。

原始 PINN 方法采用单分支结构，输入为 (x, y, θ) ，同时输出散射场与介电常数分布，对于原始 PINN 不同角度对应的不同介电常数分布取平均处理。原始 PINN 使用与本文方法相同的观测数据、物理模型、优化器及训练轮数、采样总点数、硬约束方法等。但其不引入自适应动态配点、多尺度激活机制、双分支解耦、边缘保持正则化和残差自适应重加权等机制，因此总损失函数仅由物理残差项、观测数据项构成，权重 λ_f 、 λ_d 分别设置为 1、100。

另一方面，子空间优化方法采用标准 SOM 流程实现像素级成像。为与本文设置保持一致，SOM 采用 1 cm 的均匀离散尺度，从而使目标域和求解域分别离散为 100×100 和 200×200 像素单元，优化器使用共轭梯度法（Conjugate Gradient, CG），初始值均设为 0，收敛阈值被设置为 10^{-4} 。

在评价指标方面，本章主要关注介电常数分布的重建精度。设真实介电常数分布为 $\varepsilon_r^{true}(x, y)$ ，重建结果为 $\hat{\varepsilon}_r(x, y)$ ，则首先采用相对误差作为定量评价指标，即：

$$\text{相对误差} = \frac{\|\hat{\boldsymbol{\epsilon}}_r - \boldsymbol{\epsilon}_r^{\text{true}}\|_2}{\|\boldsymbol{\epsilon}_r^{\text{true}}\|_2} \quad (5.16)$$

其中 PINN 评估介电常数分布的取点与 SOM 一致，点位置位于 SOM 每个像素的中心点。

进一步地，为了从图像结构角度评价重建结果与真实分布之间的一致性，本章还引入结构相似性指数（Structural Similarity Index Measure, SSIM），其定义为：

$$\text{SSIM} = \frac{(2\mu_{\hat{\epsilon}}\mu_{\epsilon} + c_1)(2\sigma_{\hat{\epsilon}\epsilon} + c_2)}{(\mu_{\hat{\epsilon}}^2 + \mu_{\epsilon}^2 + c_1)(\sigma_{\hat{\epsilon}}^2 + \sigma_{\epsilon}^2 + c_2)} \quad (5.17)$$

式中， $\mu_{\hat{\epsilon}}$ 和 μ_{ϵ} 分别表示重建图像与真实图像的均值， $\sigma_{\hat{\epsilon}}^2$ 和 σ_{ϵ}^2 分别表示对应方差， $\sigma_{\hat{\epsilon}\epsilon}$ 表示二者的协方差， c_1 和 c_2 为防止分母为零而设置的正常数。SSIM 取值越接近于 1，说明重建结果在亮度、对比度和结构分布上与真实介电常数图像越一致。

编程语言及版本、实验平台与前文一致。

5.3.2 低频和高频下规则目标成像验证

为验证所提双分支 PINN 方法在不同频率条件下的像素级成像能力，本节选取一个规则介质目标开展两个频点成像实验。目标设置为位于求解域中心的正方形介质块，其中心与求解域中心重合，边长为 0.4 m，相对介电常数取 4，如图 5.3 所示。在此基础上，选取 0.3 GHz 和 3 GHz 两个频点分别代表低频和高频场景进行成像验证。与前文不同的是，本节仅采用两个入射方向，即沿 $+x$ 和 $-x$ 方向入射的平面波。由于该目标几何形状简单、介电常数均匀且边界明确，因此该算例能够较好地反映方法在不同频率下对目标轮廓、区域均匀性以及边界过渡的恢复能力。




图 5.3 规则目标的相对介电常数分布示意图

图 5.4 给出了在 0.3 GHz 下规则正方形目标的成像结果对比。图中分别展示了原始 PINN 方法、SOM 方法和本文方法对应的重建结果。从整体结果来看，在 0.3 GHz 下，三种方法均能够恢复目标的大体位置和方形轮廓，但边界仍存在不同程度的扩散。此时，原始 PINN 方法能够恢复目标的大致介电常数分布，但整体轮廓和真实目标差距较大，扩散现象较明显；SOM 方法和本文方法重建得到的目标轮廓更加接近真实方形边界，目标内部介电常数分布也更加均匀，说明在较低频率条件下，双分支 PINN 能够对介电常数分布恢复起到较好的约束作用。




图 5.4 低频下规则目标的成像结果对比。(a)原始 PINN 结果；(b)SOM 结果；(c)本文提出的双分支 PINN 结果




图 5.5 高频下规则目标的成像结果对比。(a)原始 PINN 结果；(b)SOM 结果；(c)本文提出的双分支 PINN 结果

图 5.5 将频率进一步提升至 3 GHz 时，高频观测数据中包含了更强的局部结构信息，但同时也会使反演问题中的非线性和局部振荡更加突出。图中可以看出，原始 PINN 方法已经在这种频率下完全失效，无法还原介电常数的分布。SOM 方法在高频条件下虽然仍能维持目标的大体轮廓，但边界区域的平滑化趋势更加明显，且目标内

部区域明显不均衡、背景伪影较明显；相比之下，本文方法在 3 GHz 下仍能较清晰地恢复正方形目标的四条边界，并保持目标内部区域的相对均匀，同时抑制了背景伪影，说明所提双分支 PINN 框架在高频条件下仍具有较好的成像稳定性和边界恢复能力。




图 5.6 高频下规则目标两种方法损失函数收敛曲线

图 5.6 展示了在高频规则目标成像条件下，原始 PINN 和本文方法的损失函数收敛曲线。整体来看，本文方法的损失函数下降更快，且始终低于原始 PINN。随着迭代进行，原始 PINN 在较高损失水平附近逐渐趋于平缓，而本文方法仍可继续稳定下降，并最终收敛到更低数量级。该结果表明，本文方法在高频条件下具有更好的收敛性能和优化效果。

为了更直观地比较不同方法在两种频率下的整体成像性能和效率，表 5.1 汇总了 SOM 方法、原始 PINN 方法和本文方法在 0.3 GHz 和 3 GHz 条件下的成像相对误差、结构相似性指数 SSIM 以及所用时间。对于 0.3 GHz 低频情形，原始 PINN 的成像相对误差为 0.3908，SSIM 为 0.821，说明其重建结果与真实目标之间仍存在一定偏差。相比之下，SOM 和本文方法均能够显著改善成像质量。其中，本文方法的成像相对误差降低至 0.1292，SSIM 提高至 0.944，在三种方法中表现最优。该结果表明，本文方法在低频条件下能够较准确地恢复目标的介电常数分布，并较好地保持目标结构特征。3 GHz 高频场景下，原始 PINN 的成像性能明显下降，其成像相对误差增大至 1.7478，SSIM 下降至 0.287，在高频条件下原始 PINN 已难以获得有效的重建结果。相比之下，SOM 和本文方法仍保持了较好的成像能力。其中，本文方法的成像相对误差为 0.1341，低于 SOM 的 0.1592；SSIM 为 0.930，高于 SOM 的 0.912，说明本文提出的双分支 PINN 在该高频算例下具有更高的重建精度和更好的结构保持能力。

从计算时间来看, SOM 在两种频率下均表现出一定的效率优势, 而本文方法的耗时略高于 SOM, 但明显优于高频条件下的原始 PINN 结果。综合成像相对误差、SSIM 及计算时间可以看出, 本文方法在保证较高成像质量的同时, 计算代价处于可接受范围内, 尤其在高频条件下仍表现出较好的稳定性与适用性。

进一步比较低频和高频两种情形可以发现, 频率变化不仅影响观测数据中包含的信息量, 也会改变逆散射问题本身的求解难度。低频条件下, 电磁波波长较长, 观测数据对目标整体位置和大尺度轮廓较为敏感, 因此各类方法通常都能够恢复目标的大致形状, 但边界细节往往偏模糊; 高频条件下, 观测数据中包含更多局部结构信息, 有利于目标边界和细节特征的恢复, 但同时也会导致控制方程残差更复杂、优化景观更崎岖, 从而更容易出现局部振荡和收敛困难。本文方法在高频条件下仍保持较稳定的成像结果, 说明其双分支解耦结构、边缘保持约束以及重加权数据一致性机制能够在一定程度上缓解高频逆散射中常见的非线性增强问题。

表 5.1 规则目标的成像计算结果对比

频率	方法	成像相对误差	SSIM	时间
0.3 GHz	原始 PINN	0.3908	0.821	947 s
0.3 GHz	SOM	0.1377	0.928	583 s
0.3 GHz	本文方法	0.1292	0.944	939 s
3 GHz	原始 PINN	1.7478	0.287	1781 s
3 GHz	SOM	0.1592	0.912	913 s
3 GHz	本文方法	0.1341	0.930	1465 s

总体而言, 通过对低频和高频下规则正方形目标的成像验证可以看出, 本文方法能够较准确地恢复目标位置、方形轮廓及其内部均匀介电常数分布, 并在整体成像误差和结构保持能力方面优于原始 PINN 方法与 SOM 方法, 即所提双分支 PINN 框架不仅适用于一般频率条件下的像素级逆散射成像, 也能够较好地适应不同频率下观测信息变化带来的成像需求。

5.3.3 噪声下复杂目标成像验证

为进一步考察所提双分支 PINN 方法在噪声干扰条件下对复杂目标的成像能力, 本节选取 Austria 形状散射体开展数值实验。该算例仍考虑二维 TM 极化频域逆散射问题, 工作频率设为 1 GHz。入射采用四个方向的平面波激励, 分别沿 $+x$ 、 $-x$ 、 $+y$

和 $-y$ 四个方向入射,即 $\theta=0、\pi/2、\pi、3\pi/2$ 。观测的散射场数据中分别加入 0% (即无噪声)、25%和 50%的高斯白噪声,从而验证不同噪声水平下方法的成像稳定性。

为适应本文所采用的目标活动区域尺寸,Austria 形状目标由两个圆形区域和一个圆环区域组合而成,并在域内按比例缩放后进行布置。具体而言,上方两个圆形区域的半径均设为 0.10 m,圆心分别位于 $(0.15,0.30)$ m 和 $(-0.15,0.30)$ m;下方圆环区域的圆心位于 $(0,-0.10)$ m,内半径和外半径分别取 0.175 m 和 0.275 m。上述三个子区域的并集构成 Austria 形状目标,其内部相对介电常数统一设为 3,背景区域相对介电常数为 1。图 5.7 给出了 Austria 形状目标的真实相对介电常数分布。可以看出,该目标整体几何轮廓较规则目标更加复杂,既包含局部曲边的特征,也包含中空区域,因此能够更有效地检验成像方法对复杂边界、局部细节以及连通结构的恢复能力。




图 5.7 Austria 形状目标的相对介电常数分布示意图

图 5.8、图 5.9、图 5.10 分别给出了在 0% (无噪声)、25%和 50%高斯白噪声条件下,原始 PINN 方法、SOM 方法和本文方法对 Austria 形状目标的成像结果对比。总体来看,在无噪声条件下,三种方法均能够恢复目标的大致位置和主要轮廓,但原始 PINN 结果已存在较大的边界扩散和局部失真,SOM 方法能够较好恢复目标主体区域,而本文方法在边界完整性和边界扩散方面表现更优。

加入 25%噪声后,原始 PINN 结果中的结构模糊加重,且无法恢复正确的介电常数数值;SOM 方法虽仍能辨识目标主体形状,但边界连续性有所下降;相比之下,本文方法仍能较清晰地区分上部双圆结构和下部圆环区域。

进一步当噪声增大至 50%时,三种方法的成像质量均有所下降,但原始 PINN 退化最为明显,已无法识别目标的轮廓,SOM 次之,其边界扩散更加明显,本文方法仍能够较好保持目标的主要几何轮廓和整体拓扑结构,体现出更好的抗噪性能。




图 5.8 无噪声下复杂目标成像结果对比。(a)原始 PINN 结果；(b)SOM 结果；(c)本文提出的双分支 PINN 结果




图 5.9 25%高斯白噪声下复杂目标成像结果对比。(a)原始 PINN 结果；(b)SOM 结果；(c)本文提出的双分支 PINN 结果




图 5.10 50%高斯白噪声下复杂目标成像结果对比。(a)原始 PINN 结果；(b)SOM 结果；(c)本文提出的双分支 PINN 结果

图 5.11 进一步给出了本文方法在三种噪声条件下的损失函数收敛曲线。总体来看，随着迭代进行，不同噪声水平下的损失函数均能够持续下降并最终趋于稳定，在

无噪声情况下，本文提出的双分支 PINN 方法的损失最终收敛值是最小的。结果表明所提方法在复杂目标成像问题中具有较好的收敛性。




图 5.11 三种噪声条件下 Austria 形状目标损失函数收敛曲线

表 5.2 Austria 形状目标的成像计算结果对比

噪声水平	方法	成像相对误差	SSIM	时间
0%	原始 PINN	0.3616	0.833	1067 s
0%	SOM	0.1260	0.918	723 s
0%	本文方法	0.1194	0.944	1012 s
25%	原始 PINN	0.7621	0.412	1025 s
25%	SOM	0.1387	0.911	730 s
25%	本文方法	0.1219	0.932	1014 s
50%	原始 PINN	0.9892	0.381	1028 s
50%	SOM	0.1402	0.907	719 s
50%	本文方法	0.1286	0.923	996 s

为了更直观地比较不同方法在噪声条件下的整体成像性能，表 5.2 汇总了原始 PINN 方法、SOM 方法和本文方法在三种噪声水平下的成像相对误差、结构相似性指数 SSIM 以及计算时间。由表 5.2 可以看出，在 Austria 形状复杂目标成像任务中，随着噪声水平由 0%提高至 50%，三种方法的成像性能均受到一定影响，但不同方法对噪声的敏感程度存在明显差异。原始 PINN 方法的性能退化最为显著，其成像相对误差由无噪声时的 0.3616 迅速增大至 25%噪声下的 0.7621，并在 50%噪声时进一步上

升到 0.9892；与此同时，SSIM 由 0.833 下降至 0.412 和 0.381，说明在噪声干扰下原始 PINN 难以稳定保持目标的结构特征与整体轮廓。相比之下，SOM 方法在三种噪声条件下均表现出较好的稳定性，其成像相对误差分别为 0.1260、0.1387 和 0.1402，SSIM 分别为 0.918、0.911 和 0.907，随噪声增强略有下降。本文方法在三种噪声水平下分别取得了 0.1194、0.1219 和 0.1286 的成像相对误差，以及 0.944、0.932 和 0.923 的 SSIM，整体上均优于 SOM 和原始 PINN，在 25%以及 50%噪声条件下均未对成像相对误差和 SSIM 指标产生过大影响，表明该方法在中等以及较高噪声干扰下仍具有较强的结构恢复能力和较好的成像稳定性。

从计算时间来看，本文方法整体略高于 SOM，但快于原始 PINN。可以看出，本文方法在未显著增加计算代价的前提下，有效提高了复杂目标在噪声环境下的重建精度和结构保持能力，体现出更优的抗噪鲁棒性和综合成像性能。

针对 Austria 形状复杂目标的噪声成像实验表明，本文方法不仅能够在无噪声条件下较准确地恢复目标轮廓，而且在不同程度的高斯白噪声干扰下仍能较好地保持目标的主体结构 and 主要边界特征。相较于原始 PINN 方法和 SOM 方法，本文方法在成像精度、结构保持能力以及噪声鲁棒性方面均表现出更明显的优势。

5.3.4 实验数据成像验证

为进一步验证所提方法在真实测量条件下的适用性，本节采用 Institut Fresnel 数据库^[91]中的一个典型实验案例开展成像验证。与前两节基于数值仿真生成的散射场数据不同，本节直接使用实测散射场进行反演，因此更能够反映不同方法在测量误差、系统误差以及实际环境扰动共同作用下的成像能力。为便于与前文保持一致，本节仍将原始 PINN 方法、SOM 方法和本文提出的双分支 PINN 方法进行对比分析。

该实验的几何布置如图 5.12 所示。实验系统在接收机轨道上均匀布设 49 台接收机和 36 台发射机，对应 36 个均匀间隔的入射方向；接收散射场数据的观测位置分布在均匀圆周上。散射体为一个介质圆柱，其半径为 15 mm，圆柱中心位于圆轨中心下方 30 mm 处，圆柱相对介电常数为 3 ± 0.3 。在成像过程中，选取的目标区域 D 为一块大小为 18 cm×18 cm 的正方形区域，并将其作为重建区域。该实验数据覆盖 1 GHz 至 8 GHz 频率范围，步进为 1 GHz。考虑到较低频条件下测量数据的稳定性以及与本文方法前述验证场景的一致性，本节仅采用 1 GHz 下的实验数据开展成像分析。

从工程应用角度看，该实验布置可视为一种典型的圆周多站式微波成像系统，通

过多发射机和多接收机在目标外围采集多视角的场数据,并进一步重建目标区域内的介电常数分布。因此,本节实验结果不仅验证了本文方法在真实测量条件下的适用性,也说明了其在普遍存在测量噪声、系统误差等因素的实际微波成像系统中的应用潜力。具体而言,该方法可实际用于医学微波成像中异常组织区域的定位与介电特性重建,也可用于工业无损检测中介质材料内部缺陷、夹杂或脱粘区域的识别。




图 5.12 实验场景的几何布置

图 5.13 给出了三种方法在该实验数据下的成像结果对比。总体来看,除原始 PINN 外,SOM 方法和本文方法均能够在一定程度上恢复散射体所在的大致区域。原始 PINN 方法在实验数据条件下,其单分支结构对测量噪声和模型误差更为敏感,几乎无法完成成像任务。SOM 方法能够较清晰地恢复目标主体区域,成像结果较稳定,但存在明显的背景伪影,对目标介电常数峰值和局部轮廓的恢复仍有不足。相比之下,本文方法得到的重建结果在目标定位、轮廓清晰度等方面均表现更优,不仅能够更准确地给出圆柱散射体的位置,而且在边界恢复和背景抑制方面也更接近真实情况。




图 5.13 实验数据成像结果对比。(a)原始 PINN 结果；(b)SOM 结果；(c)本文提出的双分支 PINN 结果

从实验数据成像的特点来看,与理想仿真数据相比,实测散射场通常包含更复杂的误差来源,例如测量噪声、系统校准偏差以及实际介质参数与理想模型之间的不完全一致。这些因素会进一步加剧逆散射问题的不适定性,使得成像过程更容易出现边界失真、伪影增强和局部振荡等现象。原始 PINN 方法由于场预测与介电常数恢复共用同一分支,在实验数据条件下更容易受到不同任务之间梯度竞争的影响,因此其成像结果退化较为明显。SOM 方法基于离散优化框架,整体稳定性较好,但在目标边缘保持和局部细节恢复方面仍受限于其本身的离散更新方式。本文方法则通过场预测与介电常数恢复的双分支解耦,在结构层面减少了角度相关信息对介电常数重建路径的干扰;同时,边缘保持正则化有助于抑制非物理振荡,残差自适应重加权机制则能够减弱异常观测样本对优化过程的影响,因此在实验数据条件下仍表现出较好的成像稳定性和结构恢复能力。

表 5.3 进一步汇总了三种方法在该实验案例下的定量评价结果。由表中可以看出,原始 PINN 方法的成像相对误差大、SSIM 低,说明其对真实测量数据的适应能力有限;SOM 方法在定量指标上较原始 PINN 有所改善,表明传统迭代反演方法在实验数据条件下仍具有较好的稳定性;本文方法则在成像相对误差和 SSIM 两项指标上均取得最优结果,但本文方法在计算时间方面受限于 GPU 的性能和内存,略逊于 SOM 方法,说明所提双分支 PINN 框架不仅能够在数值仿真条件下保持较高精度,在真实测量数据条件下同样具有较好的泛化能力和实际应用潜力。

表 5.3 实验数据成像计算结果对比

方法	成像相对误差	SSIM	时间
原始 PINN	1.3241	0.379	849 s
SOM	0.1225	0.892	759 s
本文方法	0.1064	0.903	820 s

需要指出的是,SOM 方法和本文方法的重建介电常数峰值均位于 2.7 左右,峰值的误差较大,考虑到这可能与入射场近似、测量噪声、系统校准误差以及二维模型对实际实验场景的简化有关,上述峰值差异是可以接受的。

此外,图 5.14 给出了原始 PINN 方法与本文方法在该实验案例下的损失函数收敛曲线。可以看出,在实验数据条件下,原始 PINN 方法损失难以持续降低并呈现不收敛趋势,在训练后期停留在很高的损失水平。本文方法的损失下降过程更平稳,收敛速度更快,最终收敛值也更低。

基于实验数据的成像结果表明，本文提出的双分支 PINN 方法在真实测量场景下仍能够较准确地恢复介质散射体的位置和介电常数分布，并在边界清晰度、背景抑制能力以及整体结构保持方面优于原始 PINN 方法和 SOM 方法。这说明所提方法不仅适用于理想化数值仿真问题，也具备较好的实验数据适应能力和实际应用潜力。




图 5.14 实验数据成像两种方法损失函数收敛曲线

5.4 本章小结

本章围绕像素级电磁逆散射问题展开研究，针对传统单分支 PINN 在场预测与介电常数重建任务之间存在梯度冲突、复杂目标边界模糊以及噪声条件下稳定性不足等问题，提出了基于双分支结构的像素级 PINN 成像方法。其特点是通过构建场预测分支与介电常数反演分支，显式解耦角度相关散射场任务与角度无关介质参数恢复任务；同时引入边缘保持正则化方法增强成像结果的边界清晰度，并利用残差自适应的数据一致性重加权机制降低异常观测样本和强噪声数据对训练过程的干扰。

数值结果表明，在不同频率的规则目标成像中，本文方法精度均优于原始 PINN 方法和 SOM 方法，并在高频条件下表现出较好的收敛性和稳定性；在复杂目标噪声成像中，选取 Austria 形状散射体为成像目标，本文方法在不同噪声水平下均取得了更低的成像相对误差和更高的 SSIM；在实验数据成像中，本文方法的成像相对误差为 0.1064，SSIM 为 0.903，优于原始 PINN 的 1.3241、0.379 以及 SOM 的 0.1225、0.892，能够更准确地恢复目标的结构与介电常数分布，虽然计算时间略高于 SOM，但低于原始 PINN。上述结果表明，所提双分支 PINN 方法能够实现较高质量的介电常数重建，而且在真实测量场景下具备较好的泛化能力、噪声鲁棒性和工程应用价值。

结论

本文围绕电磁散射与逆散射问题中传统数值方法计算成本高、纯数据驱动方法物理一致性不足，以及现有 PINN 方法在高频、复杂边界和噪声条件下稳定性有限等问题，系统开展了电磁散射与逆散射问题的物理信息神经网络方法研究。针对电磁散射、参数级电磁逆散射和像素级电磁逆散射三个层面，分别构建了相应的 PINN 建模与优化方法，并通过数值仿真与实验数据验证了所提方法的有效性。本文的主要结论和创新点如下：

(1) 针对频域电磁散射问题，本文建立了适用于二维 TM 极化场景的 PINN 建模方法，并提出频率调制多尺度激活机制和基于残差引导的自适应动态配点策略，从网络表达能力和训练点配置两个层面提升了 PINN 在高频、强振荡及多尺度散射场景下的适应能力。数值结果表明，所提方法在不规则低对比度目标和高频高对比度复合目标散射计算中均能够较准确地恢复场分布，并表现出较好的收敛性能与训练稳定性。在高频高对比度复合目标算例中，平均绝对误差仅为 0.0971/0.0782（实部/虚部），远优于原始 PINN 的 0.4251/0.5700，为后续逆散射问题求解奠定了较可靠的正问题基础。

(2) 针对参数级电磁逆散射问题，本文提出了基于硬约束 PINN 的参数级电磁逆散射方法。该方法通过将多视角入射信息编码引入网络输入，并采用硬约束方式将边界条件嵌入网络输出，同时结合可微界面平滑技术和不规则目标的傅里叶级数参数化边界建模，实现了目标几何参数与材料参数的联合反演。数值结果表明，对于不规则介质目标，本文方法的介电常数相对误差、几何参数最大相对误差可降至 0.0320% 和 0.4780%；对于高频介质-金属复合目标，介电常数相对误差、几何参数最大相对误差分别为 0.1730%、0.5115%，对应总体耗时为 1562 s，低于 FEM+SCA 方法的 1847 s。这说明所提方法在高频、复杂目标参数级逆散射中具有较好的效率及参数辨识能力。

(3) 针对像素级电磁逆散射问题，本文提出了场预测与介电常数反演双分支 PINN 框架，并进一步引入边缘保持正则化方法和残差自适应的数据一致性重加权方法，以提高成像过程中的边界保持能力、噪声鲁棒性和训练稳定性。对于规则目标和含噪复杂目标，本文方法均能获得优于原始 PINN 和 SOM 方法的成像结果，并在不同噪声水平下保持较清晰的目标结构；对于 Institut Fresnel 实验数据，本文方法获得了 0.1064 的成像相对误差和 0.903 的 SSIM，优于原始 PINN 的 1.3241 和 0.379，也优于 SOM 的 0.1225 和 0.892，总耗时为 820 s。相关结果表明，所提方法不仅适用于理

想数值仿真场景，也具备较好的抗噪能力、实验数据适应能力和实际应用价值。

综上，本文围绕电磁散射、参数级逆散射和像素级逆散射三个层面，对 PINN 的网络结构、约束方式和训练策略进行了有针对性的设计，在保证物理一致性的基础上，提高了复杂电磁场景下的求解精度、稳定性和适用性，为高频散射分析、复杂目标参数反演和高分辨率电磁成像提供了新的思路，具有一定的理论意义和工程应用价值。

具体而言，本文所研究的方法适用于目标结构在工程上更关注典型截面电磁响应或截面成像结果的高频或复杂应用场景。例如，在雷达目标特性分析中，可用于柱状、棱柱状或截面主导型目标的散射响应快速评估；在微波成像和医学诊断中，可用于基于环形阵列或多视角测量数据的截面图像和参数重建；在无损检测中，可用于板状、层状或管状介质结构截面上的缺陷、夹杂、脱粘区域及相关参数识别。

尽管本文已取得一定研究结果，但受限于研究时间和实验条件，仍有若干问题值得进一步深入研究。后续工作可从以下几个方面展开：

（1）向三维全波电磁散射与逆散射问题推广

本文研究对象主要为二维条件下的电磁散射与逆散射问题，相关方法在二维层析场景下已取得较好效果。然而，实际工程中存在大量三维问题，其场分布更复杂、未知量更多、计算代价更高。后续可在本文方法基础上，进一步研究适用于三维电磁问题的网络构建方式、采样策略和约束处理方法，从而增强 PINN 方法的工程适用性。

（2）面向多频、多极化和多视角联合反演的拓展研究

后续可在现有框架基础上，进一步研究多频、多极化及多视角联合成像机制，构建更统一的物理约束和信息融合方式，以提升复杂目标条件下的重建精度、成像分辨率和参数恢复稳定性。

（3）计算效率与工程可部署性的进一步提升

尽管本文方法在精度和稳定性方面取得了较好结果，但 PINN 整体仍存在训练时间较长、超参数较敏感以及大规模问题求解代价较高等不足，尤其在计算速度方面，与经过优化的传统方法还有一定差距。后续可结合更高效的网络压缩技术、迁移学习策略以及与传统数值方法的混合求解机制，进一步降低训练成本，提高求解效率。

总体而言，本文的研究表明，针对具体电磁问题特性对 PINN 的网络结构、物理约束和训练机制进行有针对性的设计，是提升电磁散射与逆散射求解性能的一条有效途径。随着相关理论、算法和计算平台的进一步发展，PINN 有望在更复杂的电磁计算与成像问题中发挥更大的作用。

参考文献

- [1] 盛新庆. 计算电磁学要论 [M]. 北京: 科学出版社, 2018.
- [2] Colton D L, Kress R. Inverse Acoustic and Electromagnetic Scattering Theory [M]. Springer, 1998.
- [3] Zhang B C, Hong W, Wu Y R. Sparse microwave imaging: Principles and applications [J]. Science China Information Sciences, 2012, 55(8): 1722-1754.
- [4] Fang Y, Bakian-Dogaheh K, Moghaddam M. Real-Time 3D Microwave Medical Imaging With Enhanced Variational Born Iterative Method [J]. IEEE Transactions on Medical Imaging, 2023, 42(1): 268-280.
- [5] Li M K, Guo R, Zhang K, et al. Machine Learning in Electromagnetics With Applications to Biomedical Imaging: A Review [J]. IEEE Antennas and Propagation Magazine, 2021, 63(3): 39-51.
- [6] Ma D F, Xu W T, Zhang C, et al. Frequency-Diverse Integrated Sensing and Backscatter Communication System Utilizing High Scanning-Rate Slot Array Antenna With Inverse Scattering Approach [J]. IEEE Journal on Selected Areas in Communications, 2026, 44: 359-370.
- [7] Yang X, Meng H, Qu X, et al. Through-the-Wall Radar Imaging Grating-Lobe and Sidelobe Suppression Method Based on Imaginary Sign Coherence Factor [J]. IEEE Signal Processing Letters, 2024, 31: 2120-2124.
- [8] Randazzo A, Ponti C, Fedeli A, et al. A Two-Step Inverse-Scattering Technique in Variable-Exponent Lebesgue Spaces for Through-the-Wall Microwave Imaging: Experimental Results [J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 59(9): 7189-7200.
- [9] Rahman M S U, Abou-Khousa M A, Akbar M F, et al. A review on microwave non-destructive testing (NDT) of composites [J]. Engineering Science and Technology, an International Journal, 2024, 58: 101848.
- [10] Shah M, Gao Y, Ravan M, et al. Quantitative Defect Size Evaluation in Fluid-Carrying Nonmetallic Pipes [J]. IEEE Transactions on Microwave Theory and Techniques, 2022, 70(8): 4071-4081.
- [11] Taflove A, Hagness S C, Picket-May M. Computational electromagnetics: the finite-difference time-domain method [J]. The Electrical Engineering Handbook, 2005, 3(629-670): 15.
- [12] Yee K. Numerical solution of initial boundary value problems involving Maxwell's equations in isotropic media [J]. IEEE Transactions on Antennas and Propagation, 1966, 14(3): 302-307.
- [13] Jin J-M. The finite element method in electromagnetics [M]. John Wiley & Sons, 2015.

- [14] Harrington R F. Field computation by moment methods [M]. Wiley-IEEE Press, 1993.
- [15] Peng Z, Sheng X-Q. A flexible and efficient higher order FE-BI-MLFMA for scattering by a large body with deep cavities [J]. IEEE Transactions on Antennas and Propagation, 2008, 56(7): 2031-2042.
- [16] Sheng X-Q, Jin J-M, Song J, et al. On the formulation of hybrid finite-element and boundary-integral methods for 3-D scattering [J]. IEEE Transactions on Antennas and Propagation, 1998, 46(3): 303-311.
- [17] Stupfel B. A fast-domain decomposition method for the solution of electromagnetic scattering by large objects [J]. IEEE Transactions on Antennas and Propagation, 1996, 44(10): 1375-1385.
- [18] Yuan X, Lynch D R, Strohbehn J W. Coupling of finite element and moment methods for electromagnetic scattering from inhomogeneous objects [J]. IEEE Transactions on Antennas and Propagation, 1990, 38(3): 386-393.
- [19] Zaiping N, Yerong Z. Hybrid Born iterative method in low-frequency inverse scattering problem [J]. IEEE Transactions on Geoscience and Remote Sensing, 1998, 36(3): 749-753.
- [20] Chew W C, Wang Y-M. Reconstruction of two-dimensional permittivity distribution using the distorted Born iterative method [J]. IEEE Transactions on Medical Imaging, 1990, 9(2): 218-225.
- [21] Van Den Berg P M, Kleinman R E. A contrast source inversion method [J]. Inverse Problems, 1997, 13(6): 1607-1620.
- [22] Chen X. Subspace-based optimization method for solving inverse-scattering problems [J]. IEEE Transactions on Geoscience and Remote Sensing, 2010, 48(1): 42-49.
- [23] Lavarello R, Oelze M. A study on the reconstruction of moderate contrast targets using the distorted Born iterative method [J]. IEEE Transactions on Ultrasonics, Ferroelectrics, and Frequency Control, 2008, 55(1): 112-124.
- [24] Lavarello R J, Oelze M L. Tomographic reconstruction of three-dimensional volumes using the distorted Born iterative method [J]. IEEE Transactions on Medical Imaging, 2009, 28(10): 1643-1653.
- [25] Xu K, Zhong Y, Song R, et al. Multiplicative-regularized FFT twofold subspace-based optimization method for inverse scattering problems [J]. IEEE Transactions on Geoscience and Remote Sensing, 2014, 53(2): 841-850.
- [26] Zhong Y, Chen X. An FFT twofold subspace-based optimization method for solving

- electromagnetic inverse scattering problems [J]. IEEE Transactions on Antennas and Propagation, 2011, 59(3): 914-927.
- [27] Abubakar A, Van Den Berg P M. Iterative forward and inverse algorithms based on domain integral equations for three-dimensional electric and magnetic objects [J]. Journal of Computational Physics, 2004, 195(1): 236-262.
- [28] Raissi M, Yazdani A, Karniadakis G E. Hidden fluid mechanics: Learning velocity and pressure fields from flow visualizations [J]. Science, 2020, 367(6481): 1026-1030.
- [29] Raissi M, Perdikaris P, Karniadakis G E. Numerical Gaussian processes for time-dependent and nonlinear partial differential equations [J]. SIAM Journal on Scientific Computing, 2018, 40(1): A172-A198.
- [30] Raissi M, Perdikaris P, Karniadakis G E. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations [J]. Journal of Computational Physics, 2019, 378: 686-707.
- [31] Raissi M, Karniadakis G E. Hidden physics models: Machine learning of nonlinear partial differential equations [J]. Journal of Computational Physics, 2018, 357: 125-141.
- [32] Karniadakis G E, Kevrekidis I G, Lu L, et al. Physics-informed machine learning [J]. Nature Reviews Physics, 2021, 3(6): 422-440.
- [33] Lecun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition [J]. Proceedings of the IEEE, 2002, 86(11): 2278-2324.
- [34] Hornik K, Stinchcombe M, White H. Multilayer feedforward networks are universal approximators [J]. Neural Networks, 1989, 2(5): 359-366.
- [35] Goodfellow I J, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets [J]. Advances in neural information processing systems, 2014, 27.
- [36] Xu F, Fu S. Modeling EM Problem with Deep Neural Networks [C]//2018 IEEE International Conference on Computational Electromagnetics (ICCEM). IEEE, 2018: 1-2.
- [37] Qi S T, Wang Y P, Li Y Z, et al. Two-Dimensional Electromagnetic Solver Based on Deep Learning Technique [J]. IEEE Journal on Multiscale and Multiphysics Computational Techniques, 2020, 5: 83-88.
- [38] Ma Z C, Xu K W, Song R C, et al. Learning-Based Fast Electromagnetic Scattering Solver Through Generative Adversarial Network [J]. IEEE Transactions on Antennas and Propagation, 2021, 69(4):

- 2194-2208.
- [39] Yao H M, Jiang L, Ng M. Implementing the fast full-wave electromagnetic forward solver using the deep convolutional encoder-decoder architecture [J]. IEEE Transactions on Antennas and Propagation, 2023, 71(1): 1152-1157.
- [40] Kong D H, Cao J N, Zhang W W, et al. An AI Predictor: From Point Clouds to Scattered Far Fields for 3-D PEC Targets [J]. IEEE Transactions on Antennas and Propagation, 2024, 72(6): 5179-5190.
- [41] Qing A. An experimental study on electromagnetic inverse scattering of a perfectly conducting cylinder by using the real - coded genetic algorithm [J]. Microwave and Optical Technology Letters, 2001, 30(5): 315-320.
- [42] Huang C-H, Chiu C-C, Li C-L, et al. Time domain inverse scattering of a two-dimensional homogenous dielectric object with arbitrary shape by particle swarm optimization [J]. Progress In Electromagnetics Research, 2008, 82: 381-400.
- [43] Wei Z, Chen X D. Deep-Learning Schemes for Full-Wave Nonlinear Inverse Scattering Problems [J]. IEEE Transactions on Geoscience and Remote Sensing, 2019, 57(4): 1849-1860.
- [44] Yao H M, Sha W E I, Jiang L J. Two-Step Enhanced Deep Learning Approach for Electromagnetic Inverse Scattering Problems [J]. IEEE Antennas and Wireless Propagation Letters, 2019, 18(11): 2254-2258.
- [45] Yao H M, Zhang H H, Jiang L J, et al. Fast Electromagnetic Inversion Solver Based on Conditional Generative Adversarial Network for High-Contrast and Heterogeneous Scatterers [J]. IEEE Transactions on Antennas and Propagation, 2024, 72(4): 3485-3494.
- [46] Xiang Z, Peng W, Liu X, et al. Self-adaptive loss balanced physics-informed neural networks [J]. Neurocomputing, 2022, 496: 11-34.
- [47] Jagtap A D, Karniadakis G E. Extended physics-informed neural networks (XPINNs): A generalized space-time domain decomposition based deep learning framework for nonlinear partial differential equations [J]. Communications in Computational Physics, 2020, 28(5): 2002-2041.
- [48] Kharazmi E, Zhang Z, Karniadakis G E. Variational physics-informed neural networks for solving partial differential equations [J]. arXiv preprint arXiv:1912.00873, 2019.
- [49] Bounnah Y, Mihoubi M K, Larbi S. Physics informed neural network with Fourier feature for natural convection problems [J]. Engineering Applications of Artificial Intelligence, 2025, 146: 110327.

- [50] Wang Y, Bai J, Eshaghi M S, et al. Transfer learning in physics - informed neural networks: full fine - tuning, lightweight fine - tuning, and low - rank adaptation [J]. *International Journal of Mechanical System Dynamics*, 2025, 5(2): 212-235.
- [51] Lu L, Meng X, Mao Z, et al. DeepXDE: A deep learning library for solving differential equations [J]. *SIAM Review*, 2021, 63(1): 208-228.
- [52] Zubov K, McCarthy Z, Ma Y, et al. NeuralPDE: Automating physics-informed neural networks (PINNs) with error approximations [J]. *arXiv preprint arXiv:2107.09443*, 2021.
- [53] Cuomo S, Di Cola V S, Giampaolo F, et al. Scientific machine learning through physics-informed neural networks: Where we are and what's next [J]. *Journal of Scientific Computing*, 2022, 92(3): 88.
- [54] Kang M, Li H, Tan Q, et al. Physics-informed neural networks for the Korteweg–de Vries equation for internal solitary wave problem: Forward simulation and inverse parameter estimation [J]. *Physics of Fluids*, 2025, 37(7): 073615.
- [55] Bastek J-H, Kochmann D M. Physics-informed neural networks for shell structures [J]. *European Journal of Mechanics-A/Solids*, 2023, 97: 104849.
- [56] Al-Adly A I, Kripakaran P. Physics-informed neural networks for structural health monitoring: a case study for Kirchhoff–Love plates [J]. *Data-Centric Engineering*, 2024, 5: e6.
- [57] Zhang Z, Gu G X. Physics-informed deep learning for digital materials [J]. *Theoretical and Applied Mechanics Letters*, 2021, 11(1): 100220.
- [58] Zhang E, Dao M, Karniadakis G E, et al. Analyses of internal structures and defects in materials using physics-informed neural networks [J]. *Science Advances*, 2022, 8(7): eabk0644.
- [59] Vadyala S R, Betgeri S N. General implementation of quantum physics-informed neural networks [J]. *Array*, 2023, 18: 100287.
- [60] Kalitenko A, Pronin P. Physics-informed neural network for quantum systems with time-dependent boundary conditions [J]. *Physics Letters A*, 2025, 560: 130928.
- [61] Henkes A, Wessels H, Mahnken R. Physics informed neural networks for continuum micromechanics [J]. *Computer Methods in Applied Mechanics and Engineering*, 2022, 393: 114790.
- [62] Bai J, Jeong H, Batuwatta-Gamage C P, et al. An introduction to programming physics-informed neural network-based computational solid mechanics [J]. *International Journal of Computational*

- Methods, 2023, 20(10): 2350013.
- [63] Bao Z, Liu Y, Li Y, et al. Efficient 2D Pattern Synthesis for Planar Series-Fed Microstrip Antenna Arrays Using Physics-Informed Graph Convolutional Networks [J]. IEEE Transactions on Antennas and Propagation, 2026, 74(4): 2963-2973.
- [64] Sallam T, Wang Q, Attiya A M. Physics-informed deep neural network for low sidelobe time-modulated antenna array synthesis with harmonic suppression [J]. IEEE Access, 2025, 13: 84803-84810.
- [65] Zhao Z, Fan F, Sun Q, et al. Physics informed neural network-based high-frequency modeling of induction motors [J]. Chinese Journal of Electrical Engineering, 2022, 8(4): 30-38.
- [66] Noakoasteen O, Christodoulou C, Peng Z, et al. Physics - informed surrogates for electromagnetic dynamics using Transformers and graph neural networks [J]. IET Microwaves, Antennas & Propagation, 2024, 18(7): 505-515.
- [67] Jeong Y, Jo J, Lee T, et al. Combined analysis of thermofluids and electromagnetism using physics-informed neural networks [J]. Engineering Applications of Artificial Intelligence, 2024, 133: 108216.
- [68] Xu Y, Yang J Q, Fan K, et al. Physics - informed inverse design of programmable metasurfaces [J]. Advanced Science, 2024, 11(41): 2406878.
- [69] Liu Y-H, Liang J-C, Wang B-Z, et al. Inverse design method for electromagnetic periodic structures based on physics-informed neural network with embedded analytical models [J]. IEEE Transactions on Microwave Theory and Techniques, 2025, 73(2): 844-853.
- [70] Pan Y-Q, Wang R, Wang B-Z. Physics-informed neural networks with embedded analytical models: Inverse design of multilayer dielectric-loaded rectangular waveguide devices [J]. IEEE Transactions on Microwave Theory and Techniques, 2024, 72(7): 3993-4005.
- [71] Schoder S. Physics-informed neural networks for modal wave field predictions in 3D room acoustics [J]. Applied Sciences, 2025, 15(2): 939.
- [72] Zhang Y, Fu H, Qin Y, et al. Physics-informed deep neural network for inhomogeneous magnetized plasma parameter inversion [J]. IEEE Antennas and Wireless Propagation Letters, 2022, 21(4): 828-832.
- [73] Qin Y, Fu H, Xu F, et al. EMWP-RNN: A physics-encoded recurrent neural network for wave propagation in plasmas [J]. IEEE Antennas and Wireless Propagation Letters, 2023, 23(1): 219-223.